데이터 명세서

미술관 도슨트 RAG — 수집·전처리 데이터 (data/processed)
작성: A (PM · 데이터 리드) · 기준일 2026-10-11 · 브랜치 taemin

항목	값
대상 작가	6명 / 기획 10명 (렘브란트, 카라바조, 모네, 세잔, 고흐, 고갱)
결과 파일	사조 3 · 작가 6 · 작품 136 · 문서 221건
본문 분량	478,732자 (한국어 100%) · 500자 청크로 약 1081개
검토 상태	검토 필요 150건 / 221건 (기계 번역 59건 포함)
위치	`data/processed/` (결과) · `backend/scripts/preprocess.py` (파이프라인)
재현	같은 입력이면 같은 파일. `_SUCCESS.json`에 파일별 sha256 기록

1. 범위와 목적

이 문서는 수집한 원본(data/raw)을 적재용 파일(data/processed)로 바꾼 결과의 형식과 규칙을 정의한다. 다음 담당자(적재·청킹·임베딩, 검색, 생성)는 data/raw를 직접 읽지 않고 이 문서와 data/processed의 파일만 보고 작업한다.

- 원본은 수집 담당마다 형식이 달라도 된다. 차이는 전처리 스크립트가 흡수한다.
- 사람이 정하는 값(사조, 누락된 작가·작품 정보, 카드 설명)은 `data/mappings/catalog.json`에 둔다.
- 검수 결과는 `data/mappings/reviews.json`에 기록한다. 원본 파일은 고치지 않는다.
- data/processed는 손으로 고치지 않는다. 다음 실행 때 덮어써진다.

2. 데이터 흐름

단계	담당	입력	출력	도구
수집	전원	웹 자료	data/raw/<작가 slug>/	수동, 위키백과·위키데이터 API
번역	A	영어 원문 (lang=en)	data/raw/<작가>/*.ko.md	`scripts.translate`
전처리	A	data/raw, data/mappings	data/processed/*.jsonl, _SUCCESS.json	`scripts.preprocess`
적재	B	data/processed (load_processed)	TiDB 테이블	load_* (작성 예정)
청킹·임베딩	B	TiDB documents	document_chunks, artwork_embeddings	build_* (작성 예정)

실행 (backend/ 에서): `uv run python -m scripts.preprocess`

3. 원본 (data/raw)

원본 형식	작가	읽는 함수	처리
`dataset.json`	고흐, 고갱	read_dataset	이미 구조화됨. 필드 이름만 맞춤. sources.json은 감사용 장부라 읽지 않음
`*.md + sources.json`	모네, 세잔, 렘브란트, 카라바조	read_markdown	sources.json 항목 하나 = md 하나. 위키 문법 정리, 작품 카드 생성
`*.ko.md`	렘브란트, 카라바조, 모네, 세잔, 명암 기법	read_markdown	영어 원문의 한국어 번역. 있으면 원문 대신 사용
`timeline.json`	렘브란트, 카라바조	read_timeline	연표 사건 하나 = 생애 문서 하나

원본 형식	작가	읽는 함수	처리
`_comparisons/`	고흐·고갱, 렘브란트·카라바조	read_comparisons	작가 비교 문서, 명암 기법 문서

4. 결과 파일

파일	줄 수	내용	적재 테이블
`movements.jsonl`	3	사조	art_movements
`artists.jsonl`	6	작가	artists
`artworks.jsonl`	136	작품 카드	artworks
`documents.jsonl`	221	RAG 원문 문서	documents, document_artists, document_artworks
`artist_aliases.jsonl`	10	작가 별칭 (기획된 10명, 수집 여부 자동 계산)	적재 안 함 (챗봇 작가 인식용)
`_SUCCESS.json`	-	성공 기록. 파일별 sha256, 줄 수, 검토 필요 문서 수	-

- 인코딩 UTF-8, 한 줄에 JSON 한 건(JSON Lines). 줄 순서는 slug(문서는 doc_key) 순.
- 값이 없으면 키를 빼지 않고 null. 배열 필드는 항상 배열.
- 4개 파일을 .staging/에 모두 만든 뒤 교체하고, 마지막에 _SUCCESS.json을 쓴다. 실패하면 기존 결과는 그대로 두고 _FAILED.json에 이유를 남긴다.
- 적재 스크립트는 `load_processed(name)`으로 읽는다. _SUCCESS.json이 없거나 해시가 다르면 예외.

5. 필드 명세

5-1. movements.jsonl

필드	타입	필수	제약	설명
slug	string	예	≤100, 소문자·하이픈	사조 식별자 (예: baroque)
name	string	예	≤100	한국어 이름
name_en	string	아니오	≤100	영어 이름
description	string	아니오	-	설명. 현재 모두 null

5-2. artists.jsonl

필드	타입	필수	제약	설명
slug	string	예	≤120, 고유	작가 식별자 (예: vincent-van-gogh)
name / name_en	string	예 / 아니오	≤200	한국어 이름 / 영어 이름
movement_slug	string	예	movements에 존재	대표 사조 1개
birth_year / death_year	int	아니오	SMALLINT	생몰년
nationality	string	아니오	≤100	국적
summary	string	아니오	-	목록 카드용 짧은 소개 (한국어 생애 첫 두 문장)
portrait_url	string	아니오	≤1024	초상 이미지 (위키미디어 공용, 퍼블릭 도메인)

5-3. artworks.jsonl

필드	타입	필수	제약	설명
slug	string	예	≤160, 고유	작품 식별자 (예: the-night-watch)
artist_slug	string	예	artists에 존재	작가
movement_slug	string	예	movements에 존재	비어 있으면 작가 사조로 채움
title / title_en	string	예 / 아니오	≤255	한국어 / 영어 제목
year_label	string	아니오	≤50	화면 표기 원문 (예: c. 1893, 1665–1669)
year_start	int	아니오	SMALLINT	정렬용 숫자. 연작처럼 정할 수 없으면 null
medium / dimensions	string	아니오	≤255 / ≤100	재료 / 크기 (예: 캔버스에 유채, 363 × 437 cm)
collection	string	아니오	≤255	소장처
description	string	아니오	-	카드 설명. 사람이 쓴 설명 > 한국어 원문 > 번역본 순
image_url	string	아니오	≤1024	화면용 이미지 주소 (쿼리 문자열 제거)
image_source_url	string	아니오	≤1024	이용 조건을 확인할 원본 페이지
image_license	string	아니오	≤100	이미지 이용 조건
is_featured	bool	예	-	신규 사용자에게 먼저 보여 줄 대표 작품 (원본·매핑에서 작가별로 지정)

5-4. documents.jsonl

필드	타입	필수	제약	설명
doc_key	string	예	≤191, 고유	<작가 slug>/<원본 파일 이름>, 연표는 <작가>/timeline-NN. 재적재·검수 기준 키
doc_type	string	예	허용값 3개	artist_bio / artwork_commentary / artist_comparison (6절)
title	string	예	≤255	답변 출처에 보일 제목. 번역본은 끝에 (영문 번역)
content	string	예	MEDIUMTEXT	정제한 본문. 섹션 제목은 ## 제목 형태로 유지
artist_slugs	string[]	예	artists에 존재	생애 1명, 비교 2명 이상, 해설은 []
artwork_slug	string	해설만	artworks에 존재	해설 대상 작품. 다른 종류는 null
source_url	string	예	≤1024	원문 주소. 없으면 전처리 오류
source_name / license	string	아니오	≤255 / ≤100	출처 이름 / 이용 조건
lang	string	예	ko | en	본문 언어. 번역본은 ko
topic	string	아니오	≤30	생애 문서의 성격 (6절)
related_artwork_slugs	string[]	예	artworks에 존재	연표 사건이 언급하는 작품
needs_review	bool	예	-	사람 검토 전이면 true (7-4절)

6. 코드값

doc_type	건수	artist_slugs	artwork_slug	예
`artist_bio`	76	1명	null	생애, 주변 인물, 자화상·장소·영향 문서, 연표 사건
`artwork_commentary`	140	[]	필수	작품 해설
`artist_comparison`	5	2명 이상	null	작가 비교, 명암 기법(테네브리즘, 키아로스쿠로)

topic	건수	뜻
연표	51	스토리텔링 연표의 사건 하나 (100~400자)
생애 전체	2	작가 생애 전문 (영문 번역)
주변 인물	3	아내·연인·아들 등 (렘브란트)
작품 세계	1	자화상 연작 등
장소	1	렘브란트의 집
영향	2	카라바조 화파
기법	4	명암 기법 문서
null	157	구분 없음 (작품 해설, 한국어 생애, 고흐·고갱 문서 등)

lang: ko 221건 · en 0건

7. 변환 규칙

7-1. 본문 정제

- 요약하거나 다시 쓰지 않는다. 지우기만 한다 (답변 근거로 원문을 보여 주기 때문).
- 위키 제목(== 제목 ==)은 마크다운 제목(## 제목)으로 바꾼다. 청킹 때 섹션 경계로 쓴다.
- 통째로 지우는 섹션: 같이 보기, 각주, 참고 문헌, 외부 링크, 갤러리, References, See also, 작품·전시 목록, 대중문화 등 (하위 섹션 포함).
- 제목만 있고 본문이 없는 섹션은 지우되, 본문 있는 하위 섹션을 거느린 상위 제목은 남긴다. 각주 표식([*], [2])과 줄 끝 공백, 세 줄 이상 빈 줄을 정리한다.
- 카드 설명·작가 소개에서는 원어 병기 괄호, 발음 기호, 위키 표식을 지운다. 문서 본문에는 적용하지 않는다.

7-2. 작품 카드 값의 우선순위

원본의 작품 정보 → data/mappings/catalog.json 순으로 채우고, 뒤의 값이 앞의 값을 덮어쓴다.
image_source_url이 없고 이미지가 위키미디어 파일이면 파일 설명 페이지 주소를 만든다.

7-3. 연도

예	year_label	year_start
단일 연도	1642	1642
추정	c. 1893	1893
기간	1665–1669	1665
연작 등 정할 수 없음	1890년대–1920년대	null

7-4. 검토 상태 (needs_review)

원본	needs_review
md 형식 sources.json, timeline.json	원본의 needs_review 값 (사건별 값 우선)
dataset.json, 비교 json	record_status가 draft…이거나 review_status가 검수 완료가 아니면 true
번역본 (*.ko.md)	항상 true로 시작 (기계 번역)
reviews.json에 기록됨	본문 해시가 같으면 false. 검수 뒤 본문이 바뀌면 다시 true + 경고

검수 기록: uv run python -m scripts.preprocess review --approve "rembrandt/timeline-*" --reviewer 이름

7-5. 번역본

- 영어 원문을 gpt-5.4-mini로 번역해 *.ko.md로 저장한다. 고유명사는 연표·카드와 같은 용어집 표기를 따른다.
- 번역본이 있으면 영어 원문 대신 내보낸다 (같은 내용이 두 언어로 겹치지 않게). doc_key는 원문과 같다.

- sources.json에 번역 파일·모델·날짜·원문 해시를 기록한다. 원문이 바뀌면 전처리가 경고한다.
- 현재 59건 (영어 원문 전부). 번역할 때마다 원문과 섹션 제목 수·문단 수, 다른 언어 문자 섞임을 자동 검사한다. 영어식 연도(c. 1893)는 1893년경으로 바꾼다.

7-6. 연표

timeline.json의 사건 하나를 artist_bio 문서 하나로 만든다. 본문은 '연도 · 제목', 이야기 2~4문장, 등장 인물, 관련 작품 순이다. 관련 작품은 related_artwork_slugs로 내보내고 DB에서는 document_artworks에 저장한다. 청크 하나에 이야기 하나가 들어가도록 자르지 않는 것을 권장한다.

8. 검증 규칙

오류가 하나라도 있으면 결과를 쓰지 않고 종료 코드 1로 끝난다 (기존 결과 유지, _FAILED.json 기록). 경고는 출력만 한다.

구분	검사
오류	doc_type이 허용값 3개 중 하나
오류	작가 사조, 작품 사조(비면 작가 사조로 채운 값)가 movements에 존재
오류	작가 이름, 작품 제목 존재
오류	artist_slug, artist_slugs, artwork_slug, related_artwork_slugs 참조 대상 존재
오류	작품 slug 형식(소문자·하이픈, ≤160), 문서 제목 ≤255
오류	doc_key 중복 없음, 모든 문서에 source_url 존재
오류	생애 문서는 작가 1명, 비교 문서는 2명 이상
오류	작가마다 생애 문서 1건 이상, 작품 3점 이상
경고	작품 카드 설명 없음, 본문 200자 미만 (연표 제외), 번역 후 원문 변경, 검수 후 본문 변경

9. 현황 (2026-10-11)

작가	작품	해설	생애	연표	비교	본문(자)	한국어	검토 필요	번역
렘브란트 판 레인	27	31	7	15	4	117,318	100%	46	31
카라바조	27	27	4	14	4	141,148	100%	36	22
클로드 모네	30	30	1	0	0	93,712	100%	1	1
폴 세잔	25	25	1	0	0	78,591	100%	3	3
빈센트 반 고흐	14	14	6	10	1	14,804	100%	30	0
폴 고갱	13	13	6	12	1	14,790	100%	31	0

작품 해설·생애·연표 수는 문서 건수이며 한국어 원문과 번역본을 모두 센다. 비교 문서는 작가별로 센다 (한 문서가 두 작가에 걸침).

9-1. 화면용 값 채움률

항목	채움	비고
작가 초상 (portrait_url)	6/6	위키데이터 P18, 퍼블릭 도메인
작품 이미지 (image_url)	136/136	위키미디어, 메트 오픈 액세스(퍼블릭 도메인 확인)
이미지 출처 페이지	136/136	
카드 설명 (description)	136/136	
재료·크기	136/136 · 120/136	연작은 하나로 정할 수 없어 null, 원문과 다른 위키데이터 값은 null
정렬 연도 (year_start)	131/136	연작 등 연도를 하나로 정할 수 없으면 null
대표 작품 (is_featured)	29점	작가별 지정 (원본·매핑)

10. DB 매핑 (TiDB, Alembic 20261011_0002)

processed	DB	비고
movements.jsonl	art_movements	slug 기준 upsert
artists.jsonl	artists	movement_slug → movement_id
artworks.jsonl	artworks	artist_slug → artist_id, movement_slug → movement_id
documents.jsonl	documents	doc_key(UNIQUE), lang, topic, needs_review 포함. artwork_slug → artwork_id
documents.artist_slugs	document_artists	생애·비교 문서만
documents.related_artwork_slugs	document_artworks	연표 사건 → 작품

DB 상태: 마이그레이션 20261011_0002까지 적용 완료 (테이블 12개, alembic check 차이 없음). 구조만 준비된 상태로 모든 테이블이 0행이다. 데이터는 적재 스크립트가 넣는다.

11. 사용 방법

목적	명령 / 코드 (backend/ 에서)
전처리	`uv run python -m scripts.preprocess`
결과 읽기 (적재)	`from scripts.preprocess import load_processed; docs = load_processed("documents.jsonl")`
검토 필요 목록	`uv run python -m scripts.preprocess review --list`
검수 기록	uv run python -m scripts.preprocess review --approve "<doc_key 또는 패턴>" --reviewer <이름>

목적	명령 / 코드 (backend/ 에서)
번역 (원문 변경 시)	uv run python -m scripts.translate --artists <작가 slug>
테스트	`uv run pytest -q`

12. 알려진 한계와 다음 작업

- 작가 6/10명. 클림트, 실레, 김홍도, 정선은 원본 없음 (사조 추가 필요: 빈 분리파·표현주의, 조선 회화).
- 고흐·고갱은 보강이 끝났다 (대표작·주제별 생애·연표 추가). 다만 작품 해설은 작품당 600~850자로 여전히 짧다.
- 모네·세잔은 작품 수(30·25점)는 많지만 연표와 주제별 생애 문서가 없다. 고흐·고갱은 작품 14·13점으로 다른 작가보다 적다.
- 검토 필요 150건 / 221건. 데모 전 검수하거나 검색에서의 처리 방식을 정한다.
- 번역본 59건은 기계 번역이라 사람이 읽어 보는 검수는 아직이다 (구조·문자 검사는 통과).
- 적재·청킹·임베딩 스크립트 미작성. 적재는 나머지 작가 데이터가 모인 뒤 진행한다.

관련 문서: docs/data-collection.md (기준 전문), data/processed/README.md (필드·청킹 권장), docs/db/ (DB 설계)